Aprendizaje automático

Aprendizaje supervisado en MLB

Grado en Ciencia de Datos e Inteligencia Artificial

Héctor Fernández Cano
Diego José García Callejas

ÍNDICE

01 INTRODUCCIÓN

02 DATOS

03 KNN

04 SVM

05 REGRESIÓN LÓGÍSTICA

06 ÁRBOL DE DECISIÓN

07 MEJOR MODELO

08 CONCLUSIONES

01

INTRODUCCIÓN

01.Introducción

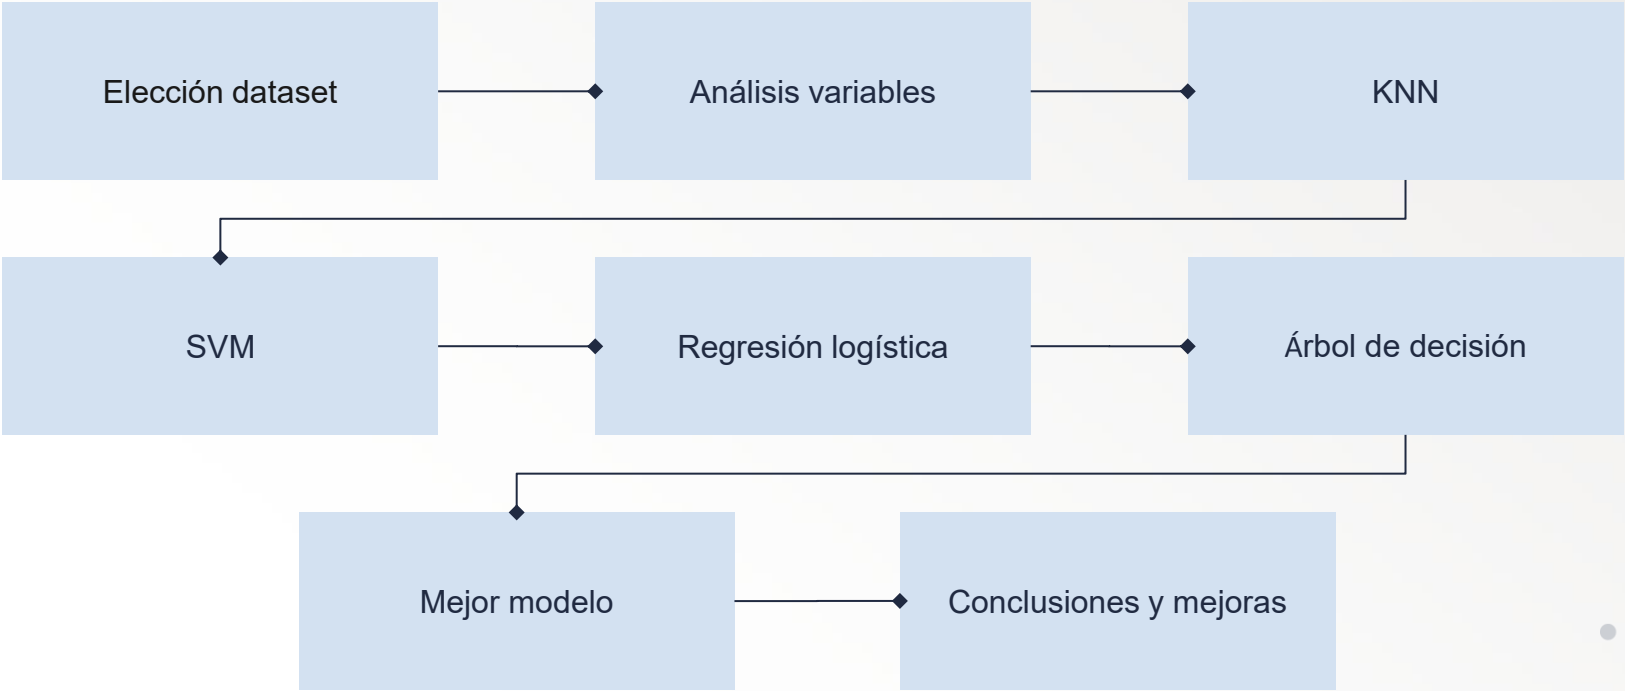

02

DATOS

02.Datos

Descripción del Dataset (MLB Statcast – Postemporada)

- Datos de lanzamientos de partidos de postemporada MLB
- Cada registro = 1 pitch (física, contextual y jugador)
- 14,096 lanzamientos · 95 variables · Datos numéricos y categóricos.
- Posibles usos : análisis predictivo en béisbol (Moneyball)

02.Datos

Descripción del Dataset (MLB Statcast – Postemporada)

- Datos de lanzamientos de partidos de postemporada MLB
- Cada registro = 1 pitch (física, contextual y jugador)
- 14,096 lanzamientos · 95 variables · Datos numéricos y categóricos.
- Posibles usos : análisis predictivo en béisbol (Moneyball)

02.Datos

Muestreo y Selección de Variables

- Muestra de 5,000 lanzamientos
- Selección de variables:

- Contexto del juego (Ej: Balls)
- Física del lanzamiento (Ej: ReleaseSpeed)
- Datos del jugador (Ej: Pthrows)

02.Datos

Transformaciones y Escalado

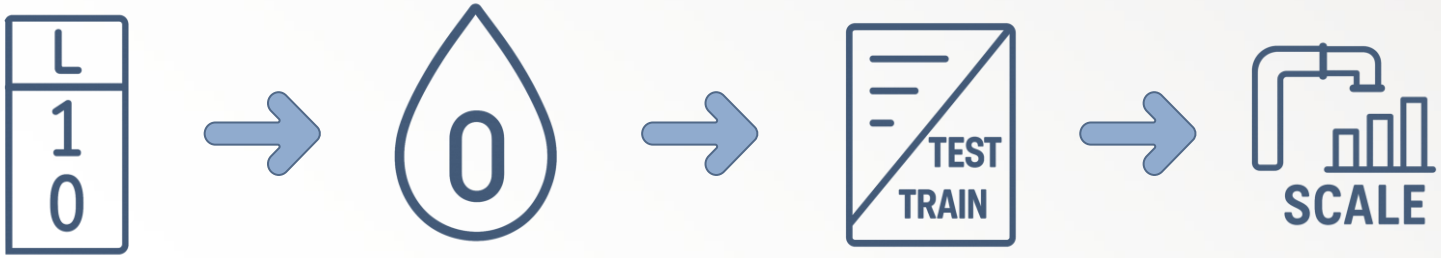

02.Datos

Distribución de la variable objetivo: *pitch-type*

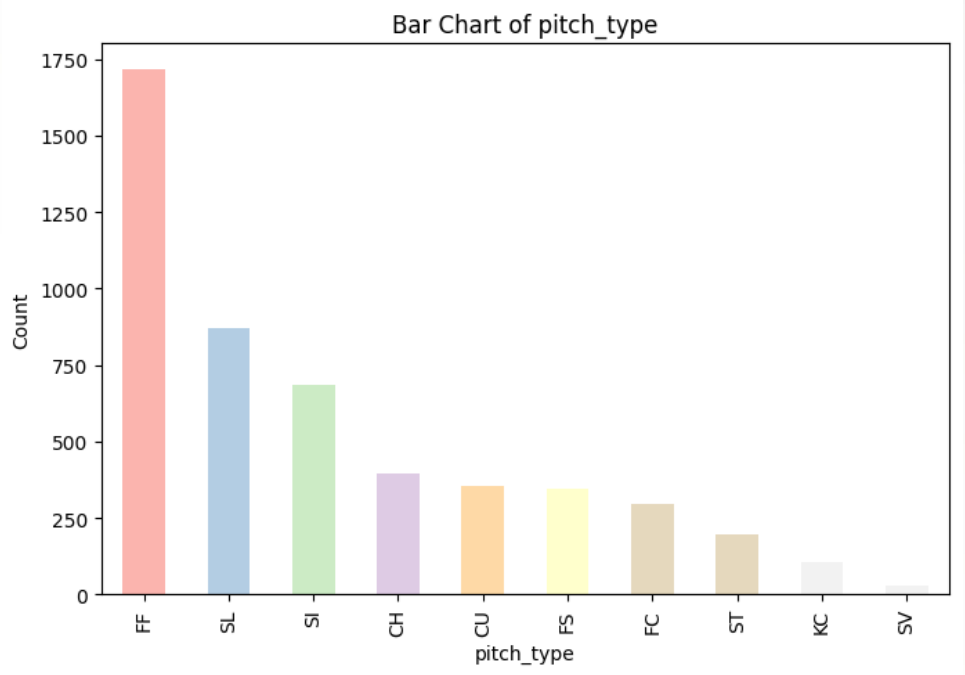

CH =Changeup (lento)
CU = Curve
FC = Cutter
FF = Fastball
FS = Splitter
KC = Knuckle Curve
SI =Sinker
SL = Slider
ST = Sweeper
SV= Slurve

03

KNN

03.KNN

Hiperparámetros y Cross-Validation (CV)

Busqueda de hiperparámetros

Vecinos (k)

- k= [1, 2, …, 20]

Métrica de distancia:

- Euclídea
- Manhattan

Cross-Validation

Pipeline:

- Escalado
- Modelo KNN

Cross-Validation:

- 10 folds
- F1-macro

Mejor F1-macro obtenido = 0.794332

03.KNN

Mejor modelo y evolución en CV

KNeighborsClassifier

Parameters

n_neighbors	1
weights	'uniform'
algorithm	'auto'
leaf_size	30
p	2
metric	'manhattan'
metric_params	None
n_jobs	None

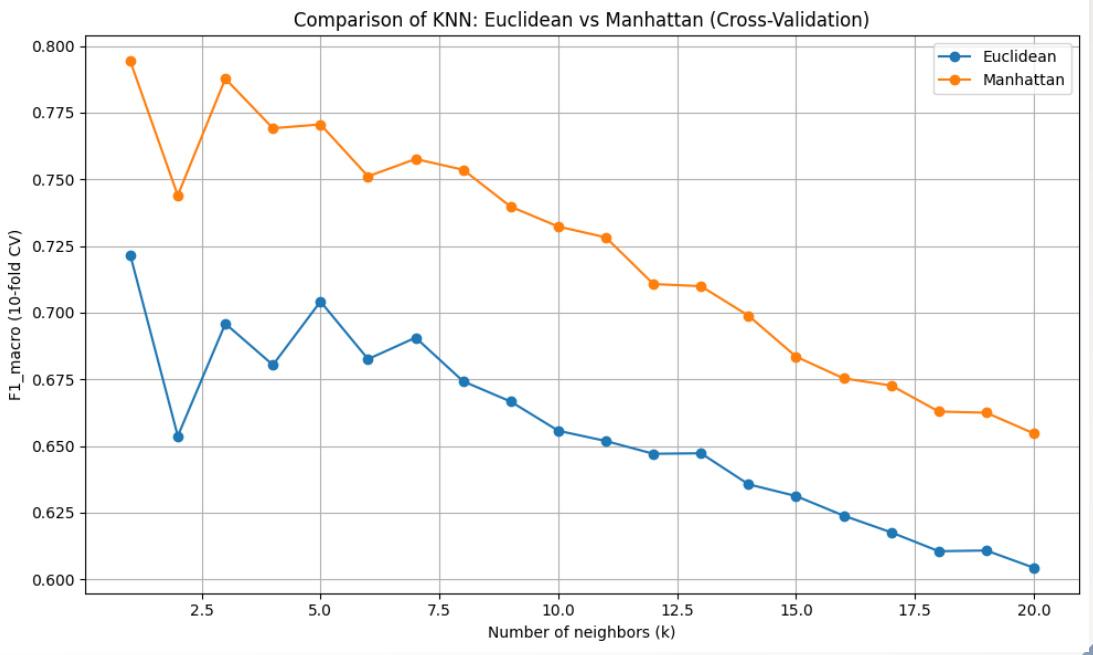

Mejor modelo: K= 1, métrica= Manhattan

04

SVM

04.SVM

Hiperparámetros y Cross-Validation (CV)

Busqueda de hiperparámetros

C

- [0.1, 1, 10, 100]

Kernel:

- Linear
- RBF

Gamma:

- Scale
- Auto

Cross-Validation

Pipeline:

- Escalado
- Modelo SVM

Cross-Validation:

- 10 folds
- F1-macro

Mejor F1-macro obtenido = 0.81425

04.SVM

Mejor modelo y evolución en CV

SVC

▼ Parameters

C	10
kernel	'rbf'
degree	3
gamma	'scale'
coef0	0.0
shrinking	True
probability	False
tol	0.001
cache_size	200
class_weight	None
verbose	False
max_iter	-1
decisionfunction_shape	'ovr'
break_ties	False
random_state	42

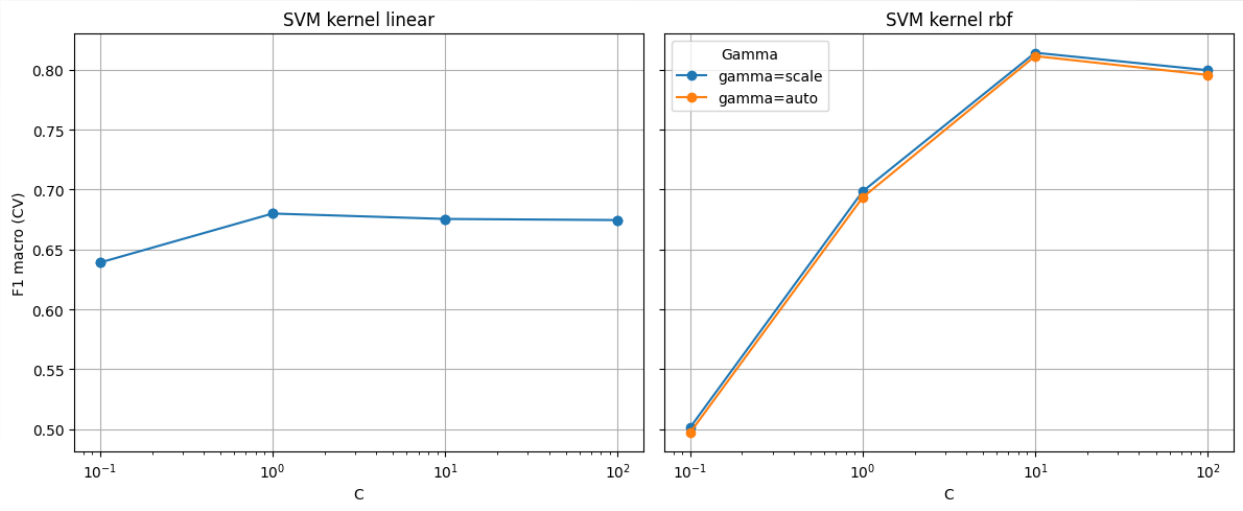

Mejor modelo: C= 10, kernel= RBF, gamma= Scale

05

REGRESIÓN LOGÍSTICA

05.RL

Hiperparámetros y Cross-Validation (CV)

Busqueda de hiperparámetros

C

- [0.1, 1, 10, 100,300,100]

Solver:

- lbfgs
- newton-cg

Class-weight:

- Balanced
- None

Cross-Validation

Pipeline:

- Escalado
- Modelo LR

Cross-Validation:

- 10 folds
- F1-macro

Mejor F1-macro obtenido = 0.67441

05.RL

Mejor modelo y evolución en CV

LogisticRegression

▼Parameters

penalty	'l2'
dual	False
tol	0.0001
C	300
fit_intercept	True
intercept_scaling	1
class_weight	None
random_state	None
solver	'lbfgs'
max_iter	5000
multi_class	'deprecated'
verbose	0
warm_start	False
n_jobs	None
l1_ratio	None

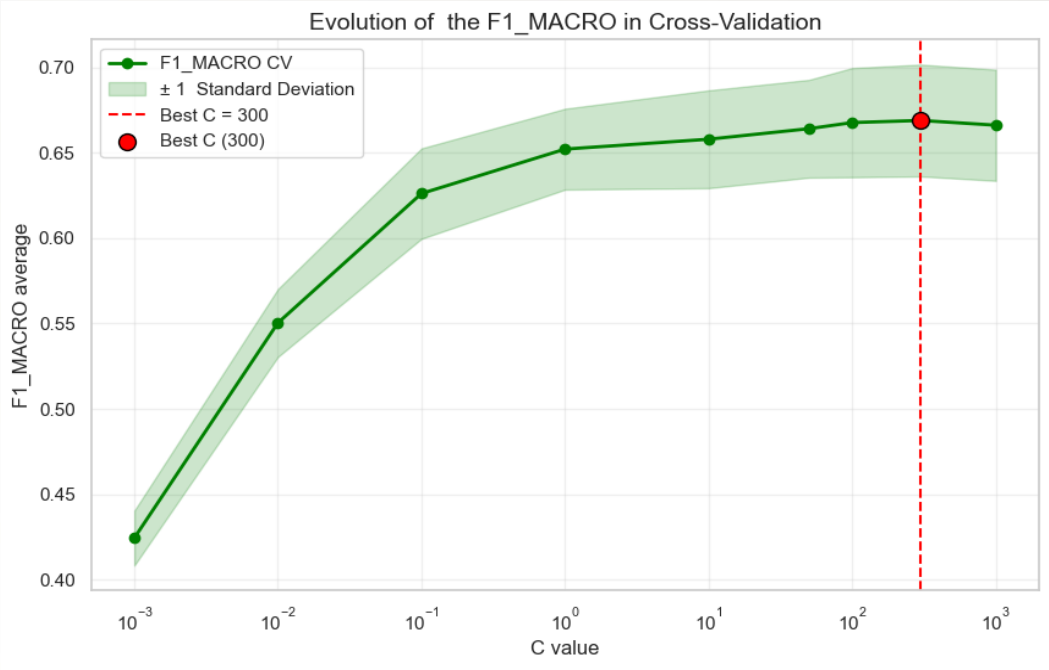

Mejor modelo: C= 300, solver= lbfgs, class-weight=None

05.RL

Importancia de las características

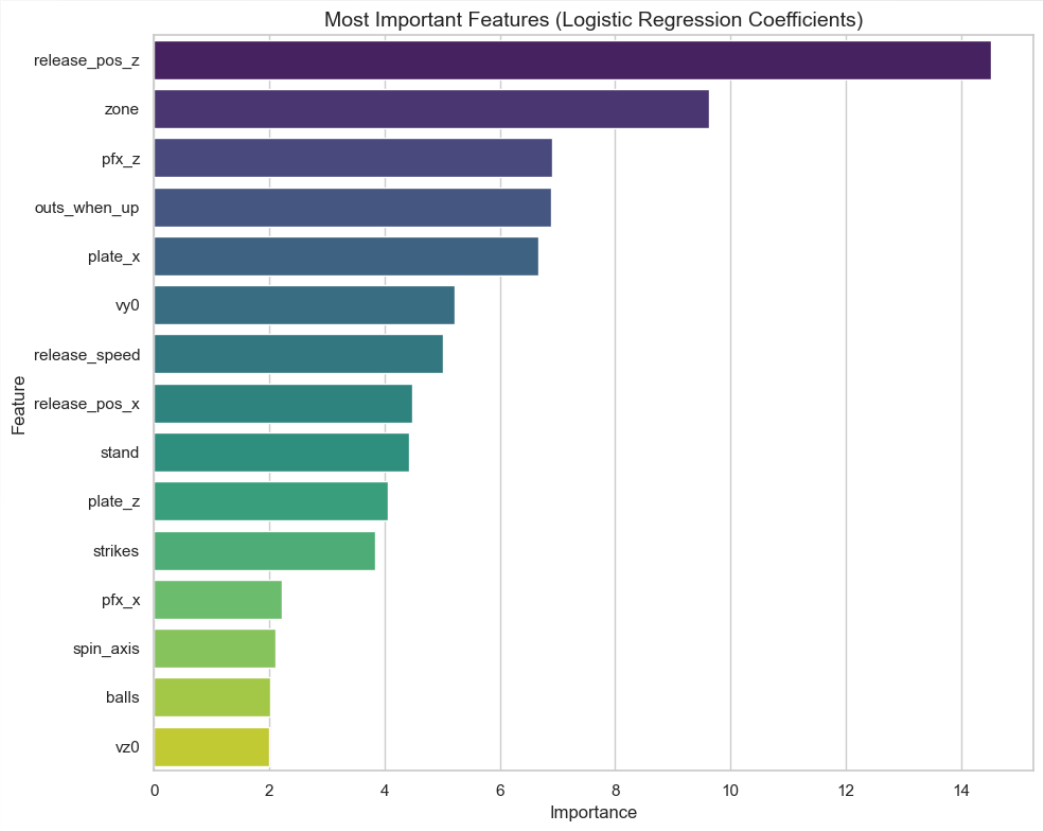

06

ÁRBOL DE DECISIÓN

06.AD

Hiperparámetros y Cross-Validation (CV)

Busqueda de hiperparámetros

min-sample-leaf

- [1, 2, 4, 8,10]

min-samples-split:

- [2,5,10,20]

max-features:

- None
- Sqrt
- Log2

criterion

- Entropy
- Gini

Ccp-alpha:

- [0,0.0005,0.001]

max-depth:

- [2,5]

Cross-Validation

Pipeline:

- Escalado
- Modelo SVM

Cross-Validation:

- 10 folds
- F1-macro

Mejor F1-macro obtenido = 0.61780

06.AD

Mejor modelo y características

DecisionTreeClassifier

▼ Parameters

criterion	'entropy'
splitter	'best'
max_depth	5
min_samples_split	5
min_samples_leaf	4
min_weight_fraction_leaf	0.0
max_features	None
random_state	None
max_leaf_nodes	None
min_impurity_decrease	0.0
class_weight	None
ccp_alpha	0
monotonic_cst	None

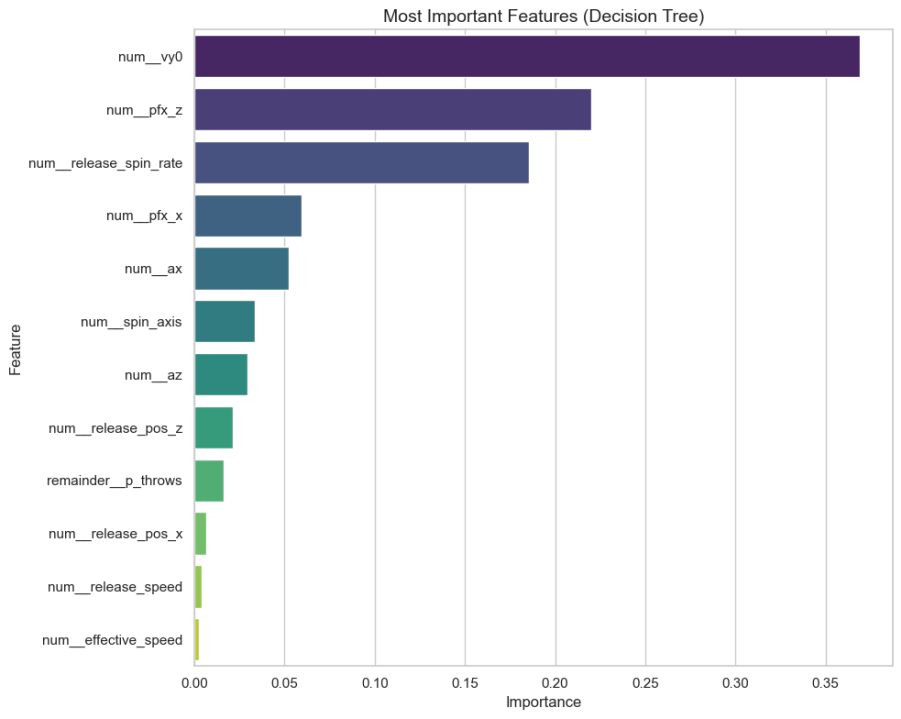

Mejor modelo: criterion=entropy, max-Depth=5,ccp

06.AD

Reglas del árbol de decisión

Velocidad inicial

Desviación vertical

Rotación inicial

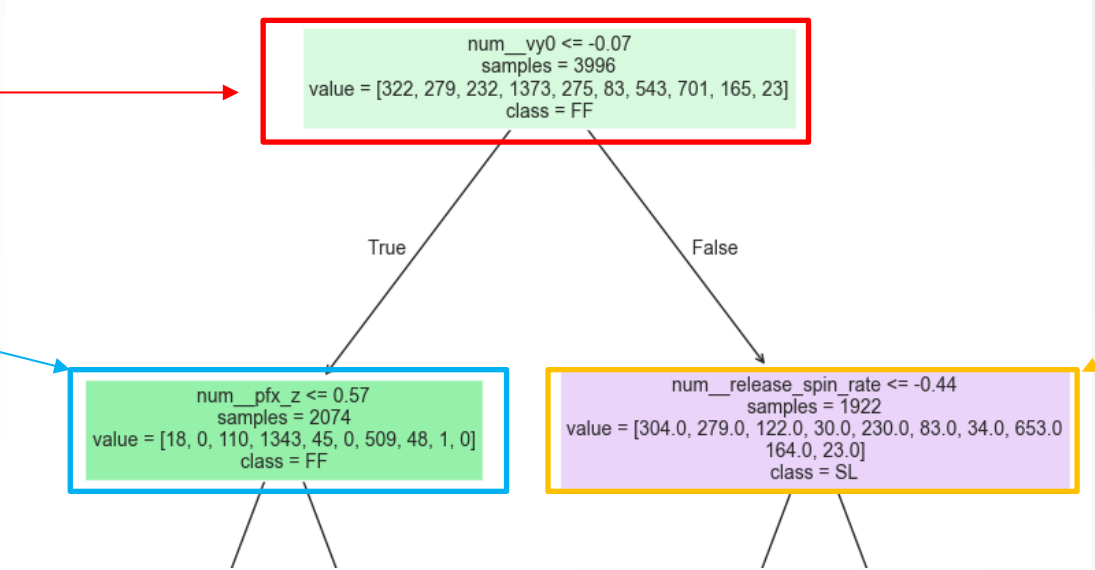

07

MEJOR MODELO

07.MEJOR MODELO

Selección del mejor modelo

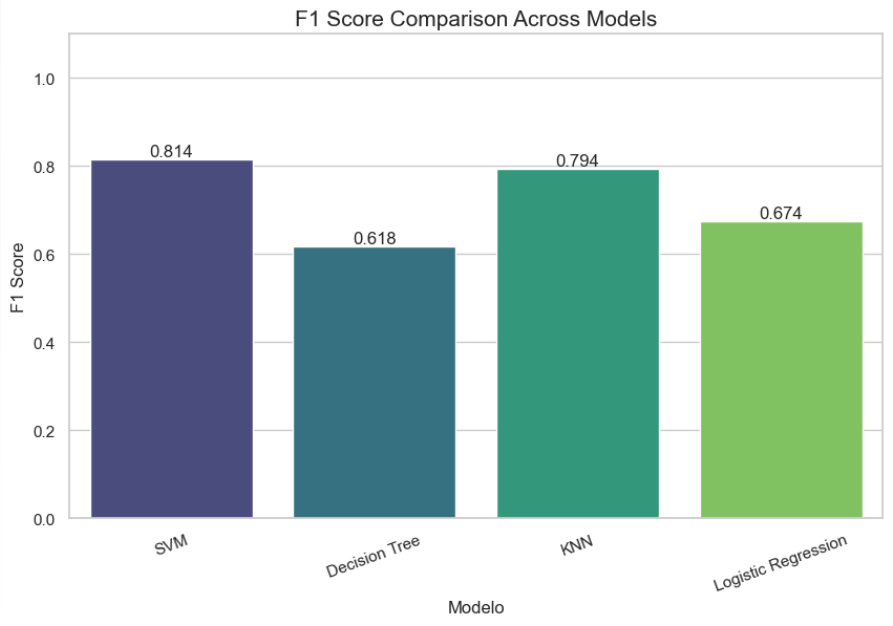

07.MEJOR MODELO

Evaluación en test

Accuracy	0.87987
Precision	0.84974
Recall	0.74884
F1	0.76726

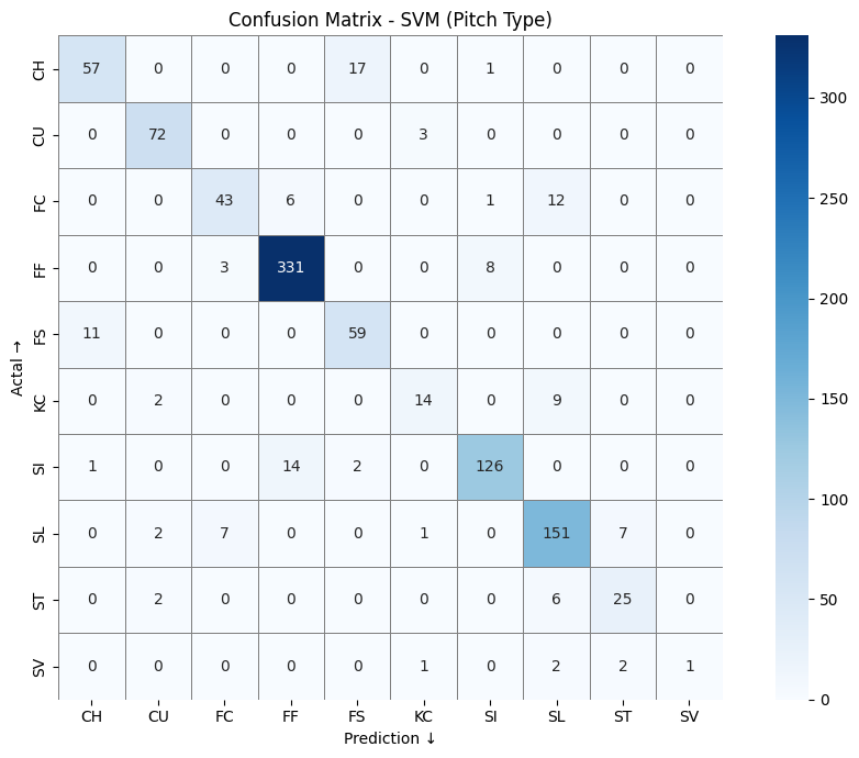

08

CONCLUSIÓN

08.CONCLUSIÓN

Posibles mejoras:

- Más datos en clases minoritarias
- Nuevos modelos
- Gráficas nuevas

¡GRACIAS!